Universidade de Brasília - UnB
Faculdade UnB Gama - FGA
Engenharia de Software

Desenvolvimento e Avaliação do Sistema "IAJuris": Integração de IA Generativa com Bases Oficiais de Jurisprudência

Autor: Matheus Ferreira Diogo e Wesley Lira
Orientador: Prof. Dr. Henrique Gomes de Moura

Brasília, DF
2025

Matheus Ferreira Diogo e Wesley Lira

Desenvolvimento e Avaliação do Sistema "IAJuris": Integração de IA Generativa com Bases Oficiais de Jurisprudência

Monografia submetida ao curso de graduação em Engenharia de Software da Universidade de Brasília, como requisito parcial para obtenção do Título de Bacharel em Engenharia de Software .

Universidade de Brasília - UnB

Faculdade UnB Gama - FGA

Orientador: Prof. Dr. Henrique Gomes de Moura

Brasília, DF

2025

Dedicatória.

Dedico esse trabalho à minha companheira, Amanda, cujo apoio, presença e compreensão foram essenciais para que eu pudesse superar essa etapa. Seu cuidado e afeto confortante e sua paciência inabalável me deram forças para sempre ir em busca dos meus objetivos, mesmo nos momentos mais tensos. Sou extremamente grato e feliz por cada frase inspiradora, que fizeram eu sempre buscar melhorar e me superar.

Agradeço também aos meus pais, que sempre estiveram presentes e foram de suma importância para essa trajetória. Em todas as etapas da minha vida, vocês me deram suporte incessante, confiança inabalável e um exemplo de como sempre vencer os obstáculos. Minha gratidão eterna a todo conselho marcante e todo ensinamento, esse apoio foi fundamental para meu desenvolvimento acadêmico e pessoal.

Matheus Ferreira Diogo

Dedicatória.

Aos meus pais e à minha família, dedico esta conquista. Vocês foram minha força e inspiração, guiando-me para enfrentar cada obstáculo de cabeça erguida. Obrigado por caminharem ao meu lado.

Wesley Lira Carvalho

"Mil cairão ao teu lado,
dez mil à tua direita,
mas tu não serás atingido.
(Bíblia Sagrada, Salmo 91, 7)"

Resumo

O volume crescente de decisões judiciais e a complexidade do sistema jurídico brasileiro tornam a pesquisa jurisprudencial um processo lento e suscetível a lacunas de informação. Paralelamente, os avanços em Inteligência Artificial têm possibilitado novas formas de organizar grandes coleções textuais, oferecendo oportunidades para aprimorar o acesso a fontes oficiais. Este trabalho apresenta o desenvolvimento do sistema IAJuris, que integra técnicas de IA generativa com mecanismos de recuperação textual para apoiar consultas jurídicas fundamentadas.

A pesquisa incluiu a análise das bases de dados públicas do CNJ e tribunais superiores, a construção de um pipeline de extração e preparação das ementas e a implementação de um modelo RAG simplificado baseado em busca lexical via FTS5. O sistema foi avaliado em um ambiente controlado, permitindo observar sua capacidade de recuperar decisões relevantes, organizar trechos jurídicos e gerar respostas estruturadas com rastreabilidade das fontes.

Como resultado, o estudo demonstra a viabilidade de integrar IA generativa a bases jurisprudenciais oficiais, apresentando um fluxo de operação transparente e alinhado a princípios de confiabilidade. O trabalho oferece fundamentos técnicos que podem orientar futuras pesquisas sobre o uso de LLMs no Direito e contribuir para tornar a consulta jurisprudencial mais ágil, verificável e acessível.

Palavras-chaves: Inteligência Artificial; Jurisprudência; Pesquisa Jurídica; Sistemas Inteligentes; Tecnologia no Direito.

Abstract

The growing volume of judicial decisions and the complexity of the Brazilian legal system make case law research a slow process prone to information gaps. At the same time, advances in Artificial Intelligence have enabled new ways of organizing large textual collections, offering opportunities to improve access to official sources. This work presents the development of the IAJuris system, which integrates generative AI techniques with textual retrieval mechanisms to support grounded legal queries.

The research included the analysis of public databases from the CNJ and higher courts, the construction of a pipeline for extracting and preparing case summaries, and the implementation of a simplified RAG model based on lexical search using FTS5. The system was evaluated in a controlled environment, allowing the observation of its ability to retrieve relevant decisions, organize legal excerpts, and generate structured responses with source traceability.

As a result, the study demonstrates the feasibility of integrating generative AI with official case law repositories, presenting a transparent and trustworthy operational flow. The work offers technical foundations that may guide future research on the use of LLMs in the legal domain and contribute to making case law research more agile, verifiable, and accessible.

Keywords: Artificial Intelligence; Case Law; Legal Research; Intelligent Systems; Legal Technology.

Lista de ilustrações

Figura 1 – Plataforma Overleaf utilizada no desenvolvimento dessa monografia . . 34
Figura 2 – Portal de Dados Abertos do STJ usado como fonte de dados 36
Figura 3 – Ferramenta para a chamada de requisições da API IA-Juris 37
Figura 4 – Ferramenta IDE para a codificação da API IA-Juris 37
Figura 5 – Fluxo de execução da API 46

Lista de tabelas

Tabela 1 – Artefatos produzidos no workshop de *Lean Inception* do projeto IAJuris. 40
Tabela 2 – Fontes-alvo e análise de viabildiade para o RAG. 41
Tabela 3 – Agrupamento das funcionalidades levantadas na Lean Inception 54

Lista de abreviaturas e siglas

IA	Inteligência Artificial
LLM	Modelo de Linguagem de Grande Escala
RAG	Retrieval-Augmented Generation
CNJ	Conselho Nacional de Justiça
STF	Supremo Tribunal Federal
STJ	Supremo Tribunal de Justiça
FTS5	Full-Text Search

Sumário

1 INTRODUÇÃO . . . 19
1.1 Contextualização . . . 19
1.2 Justificativa . . . 20
1.3 Questão da Pesquisa . . . 20
1.4 Objetivos . . . 21
1.4.1 Objetivo geral . . . 21
1.4.2 Objetivos específicos . . . 21
1.5 Organização da Monografia . . . 21

2 REFERENCIAL TEÓRICO . . . 23
2.1 Inteligência Artificial e Modelos de Linguagem . . . 23
2.2 Recuperação Aumentada por Geração (RAG) . . . 25
2.3 Ética, Governança e Diretrizes . . . 27
2.4 Direito, Jurisprudência e Segurança Jurídica . . . 29
2.5 Critérios de Qualidade e Avaliação do Sistema . . . 30
2.6 Considerações Finais do Capítulo . . . 31

3 REREFENCIAL TECNOLÓGICO . . . 33
3.1 Ferramentas de Escrita e Documentação . . . 33
3.1.1 Overleaf e LaTeX . . . 33
3.2 Tecnologias de Desenvolvimento do Protótipo . . . 34
3.2.1 Python . . . 34
3.2.2 FastAPI e Uvicorn . . . 34
3.2.3 SQLite e a Biblioteca JSON . . . 35
3.3 Ferramentas Auxliares à Pesquisa . . . 35
3.3.1 Portal de Dados Abertos (STJ) . . . 35
3.3.2 Postman . . . 36
3.3.3 Visual Studio Code (VS Code) . . . 37
3.3.4 Makefile . . . 38

4 METODOLOGIA . . . 39
4.1 Desenho do produto e planejamento . . . 39
4.2 Dados, documentação e governança . . . 41
4.2.1 Prospecção e Seleção da Fonte de Dados . . . 41
4.2.2 Conversão, Estruturação e Carga (ETL) . . . 42
4.2.3 Modelo de dados comum . . . 42

4.2.4 Documentação e Transparência (Princípios do Datasheet) 43
4.2.5 Privacidade e Confiança 43
4.2.6 Indexação para RAG (FTS5 vs. Vetores) 44
4.3 Arquitetura técnica (visão geral) 45
4.3.1 Justificativa da Arquitetura: RAG-Lite com FTS5 45
4.3.2 Fluxo de Execução da API 46
4.4 Avaliação experimental, métricas e testes do sistema 47
4.4.1 Métricas principais 49
4.4.2 Validação estatística e comparação de variantes 50
4.5 Considerações Finais do Capítulo 51

5 RESULTADOS 53
5.1 Resultados do Lean Inception 53

REFERÊNCIAS 57

1 Introdução

1.1 Contextualização

Nas últimas décadas, a evolução dos modelos de Inteligência Artificial (IA), especialmente dos Modelos de Linguagem de Grande Escala (LLMs), tem transformado a forma como a informação é produzida, organizada e acessada. Sistemas como GPT e BERT, fundamentados em arquiteturas de aprendizado auto-supervisionado e escalabilidade computacional, ampliaram significativamente as capacidades de interpretação e geração de linguagem natural (BOMMASANI et al., 2021). O relatório do *Center for Research on Foundation Models* introduz o conceito de modelos fundacionais, destacando seu impacto técnico e social, bem como preocupações relacionadas a vieses, padronização excessiva de dados e riscos éticos (BOMMASANI et al., 2021).

Essas transformações não se restringem ao campo tecnológico. A UNESCO (2021) enfatiza que o avanço da IA deve estar alinhado a princípios éticos universais, como transparência, responsabilidade e respeito aos direitos humanos, de modo a evitar discriminações e fortalecer a dignidade humana. No plano econômico, o *Future of Jobs Report 2025* do World Economic Forum (2025) aponta a IA e o *Big Data* como forças determinantes para a reconfiguração do mercado de trabalho, reforçando a importância da literacia digital, do pensamento analítico e da adaptação profissional.

No campo jurídico, tais transformações assumem relevância ainda maior. Conforme destaca Susskind (2017), o Direito vive uma ruptura estrutural, marcada pela automação de tarefas cognitivas, pela digitalização de serviços jurídicos e pelo uso intensivo de dados. A pesquisa jurisprudencial, atividade essencial para a interpretação e aplicação do Direito, enfrenta desafios decorrentes do crescimento exponencial das decisões judiciais, da heterogeneidade entre tribunais e das limitações dos mecanismos tradicionais de busca. Assim, ferramentas baseadas em IA, como modelos de linguagem e sistemas de recuperação aumentada, surgem como alternativas promissoras para ampliar o acesso à informação e fortalecer a segurança jurídica.

Nesse contexto, compreender e empregar LLMs de maneira responsável torna-se indispensável. Embora esses modelos apresentem alto potencial para apoiar atividades jurídicas, eles também estão sujeitos a erros, vieses e produções imprecisas se não forem ancorados em fontes verificáveis. Tais limitações reforçam a importância de abordagens que integrem IA generativa a dados jurídicos oficiais, garantindo rastreabilidade, precisão e alinhamento com valores éticos e institucionais.

1.2 Justificativa

A aplicação de IA no Judiciário brasileiro tem sido impulsionada pelo *Programa Justiça 4.0*, iniciativa do Conselho Nacional de Justiça (CNJ) voltada à modernização e ao uso estratégico de dados na prestação jurisdicional (JUSTIçA, 2022). Apesar disso, persiste uma lacuna entre a disponibilidade de bases públicas, como o DataJud, e o uso de ferramentas capazes de interpretar conteúdos complexos de forma confiável e semanticamente relevante.

De acordo com Ashley (2017), métodos de *Legal Analytics* podem contribuir para análises mais transparentes e embasadas, mas o uso de modelos de linguagem exige mecanismos adicionais de mitigação de riscos. Pesquisas recentes ressaltam que LLMs podem produzir respostas imprecisas quando operam sem vínculo explícito com fontes verificáveis (BOMMASANI et al., 2021). Nesse sentido, a técnica de *Retrieval-Augmented Generation* (RAG) apresenta-se como solução adequada para reduzir *alucinações* e reforçar a rastreabilidade das informações jurídicas.

A relevância jurídica do tema também se relaciona à segurança jurídica. Para Marinoni (2011), a coerência e a previsibilidade das decisões dependem da adequada compreensão e aplicação dos precedentes. Um sistema capaz de recuperar e sintetizar ementas oficiais pode apoiar a uniformização interpretativa, valorizando decisões já consolidadas e fortalecendo o papel do precedente no ordenamento.

Finalmente, o tema possui forte pertinência à Engenharia de Software. Conforme argumenta Ashley (2017), projetos que integram aprendizado de máquina ao domínio jurídico exigem arquiteturas robustas, processos estruturados de validação e mecanismos de justificativa explícita das conclusões. Ao propor o desenvolvimento do IAJuris, este trabalho busca contribuir para soluções tecnológicas que unam confiabilidade informacional, ética e boas práticas de engenharia, respondendo ao desafio de aproximar IA e Direito de forma responsável.

1.3 Questão da Pesquisa

Diante das problemáticas apresentadas, este trabalho busca responder à seguinte questão de pesquisa:

> **Como empregar a Inteligência Artificial de forma ética e confiável na análise de jurisprudência a partir de bases oficiais, garantindo precisão e rastreabilidade das respostas?**

Tal questão orienta o desenvolvimento de uma solução que integre técnicas de IA generativa e mecanismos de recuperação textual, assegurando fundamentação jurídica e

explicabilidade.

1.4 Objetivos

1.4.1 Objetivo geral

Desenvolver o IAJuris, um sistema que aplica modelos de linguagem e a técnica de RAG para realizar buscas semânticas e gerar respostas verificáveis e contextualizadas a partir de dados oficiais do Poder Judiciário.

1.4.2 Objetivos específicos

Os objetivos específicos traduzem o percurso metodológico necessário para a implementação do IAJuris, considerando as limitações práticas do projeto e as diretrizes contemporâneas em RAG, Engenharia de Software e governança de IA:

- Integrar o modelo de linguagem às bases oficiais de jurisprudência do CNJ e de tribunais superiores, utilizando APIs públicas e mecanismos de indexação textual.
- Implementar um pipeline de recuperação lexical eficiente por meio de FTS5, priorizando precisão e recuperação relevante de ementas.
- Aplicar a técnica de *Retrieval-Augmented Generation* (RAG) para gerar respostas fundamentadas e referenciadas nas fontes jurídicas consultadas.
- Avaliar a precisão, a rastreabilidade e a relevância das respostas produzidas pelo sistema, comparando-as com ferramentas jurídicas disponíveis no mercado.
- Aplicar práticas estruturadas de Engenharia de Software, incluindo versionamento (*Git*), validação funcional, e conformidade com princípios de ética e governança de IA, com foco em transparência e mitigação de riscos associados a modelos generativos.

1.5 Organização da Monografia

Esta monografia está organizada em sete capítulos, além das referências, conforme descrito a seguir:

- **Capítulo 2 – Referencial Teórico**: apresenta os fundamentos conceituais da pesquisa, incluindo Inteligência Artificial, Modelos de Linguagem de Grande Escala (LLMs), a técnica de *Retrieval-Augmented Generation* (RAG), aspectos éticos da IA e elementos centrais do Direito relacionados à segurança jurídica e jurisprudência.

- **Capítulo 3 – Referencial Tecnológico**: descreve as ferramentas empregadas no desenvolvimento, documentação e suporte técnico do projeto.
- **Capítulo 4 – Metodologia**: detalha o método de pesquisa adotado, incluindo o uso do *Lean Inception* para concepção do produto, a definição de requisitos, a arquitetura proposta e os critérios utilizados para validação do sistema.
- **Capítulo 5 – Desenvolvimento do Projeto**: apresenta a implementação do sistema *IAJuris*, descrevendo seus componentes, decisões arquiteturais, integrações com bases oficiais e o fluxo de recuperação e geração de respostas.
- **Capítulo 6 – Resultados e Discussão**: expõe os resultados obtidos, incluindo artefatos produzidos, testes executados, análise de precisão e rastreabilidade, bem como reflexões sobre as limitações e contribuições do sistema.
- **Capítulo 7 – Conclusão e Trabalhos Futuros**: sintetiza as principais conclusões da pesquisa, responde à questão orientadora do estudo e apresenta direções possíveis para a continuidade e aprimoramento da solução proposta.

Essa organização busca conduzir o leitor de forma progressiva desde os fundamentos teóricos até o desenvolvimento e validação do sistema, permitindo uma compreensão clara do percurso metodológico e das contribuições do trabalho.

2 Referencial Teórico

Para que haja um maior entendimento acerca dos assuntos abordados no trabalho, neste capítulo será apresentada a definição de Inteligência Artificial e Modelos de Linguagem, mais especificamente o recurso de Recuperação Aumentada por Geração (RAG), que será fundamental para o funcionamento do sistema. Além disso, será mostrado a importância de se manter dentro de um padrão de Ética, Governança e Diretrizes, característica extremamente importante para a área do Direito. Em seguida, serão explicados os conceitos fundamentais acerca de Direito, Jurisprudência e Segurança Jurídica, essenciais para entender o que o projeto aborda e qual sua importância no mercado. Por fim serão apresentados os Critérios de Qualidade e Avaliação do Sistema, seguidos pelas Considerações Finais do Capítulo.

2.1 Inteligência Artificial e Modelos de Linguagem

A Inteligência Artificial é compreendida como o campo da ciência e da engenharia dedicado à construção de máquinas inteligentes, especialmente programas de computador capazes de executar tarefas que exigem algum grau de raciocínio, aprendizado ou adaptação.Deste modo, a IA está relacionada ao esforço de usar computadores para compreender a própria inteligência humana, mas não se limita a métodos observáveis biologicamente. Diante disso, inteligência é a "parte computacional da capacidade de alcançar objetivos no mundo", manifestando-se em diferentes graus em pessoas, animais e máquinas. Assim, a IA não busca apenas imitar a cognição humana, mas desenvolver sistemas que, a partir de mecanismos próprios, consigam perceber, decidir e agir de maneira racional e eficiente em ambientes complexos (MCCARTHY, 2007).

De acordo com Russell e Norvig (2022), a Inteligência Artificial pode ser compreendida ao cruzar dois eixos: humano vs. racional e pensar vs. agir. Esse pensamento produz quatro perspectivas clássicas para definir e investigar o que é "inteligência" em máquinas. Essas perspectivas orientam métodos e objetivos distintos na área e ajudam a explicar por que a noção de IA envolve tanto processos internos de raciocínio quanto o comportamento observável de agentes.

- **Agir de forma humana (Teste de Turing):** foca em comportamentos indistinguíveis dos humanos, exigindo linguagem natural, representação de conhecimento, raciocínio, aprendizado e, no "teste total", percepção (visão/fala) e robótica.
- **Pensar de forma humana (modelagem cognitiva):** busca reproduzir processos mentais humanos em programas, confrontando-os com evidências de psicologia

experimental e neuroimagem.

- **Pensar racionalmente (leis do pensamento):** deriva da lógica e evolui para o raciocínio sob incerteza (probabilidade), priorizando inferências corretas a partir de premissas.

- **Agir racionalmente (agente racional):** define inteligência como escolher ações que maximizam o resultado esperado; tornou-se o modelo padrão, ainda que, na prática, considere-se a racionalidade limitada imposta por tempo e recursos.

Essas perspectivas mostram que a IA pode ser entendida tanto pelo comportamento observável quanto pelos processos internos que produzem decisões racionais. Essa diversidade de abordagens abre caminho para os avanços recentes em aprendizado de máquina, especialmente o aprendizado profundo (*Deep Learning*), que redefine como sistemas computacionais aprendem a partir de grandes volumes de dados.

Nesse contexto, o (*Deep Learning*) representa uma abordagem que permite que as máquinas aprendam diretamente a partir da experiência. Nesse sentido, o aprendizado profundo oferece uma solução para problemas intuitivos, como reconhecer padrões visuais, sons ou estruturas linguísticas, ao permitir que os computadores construam representações hierárquicas do mundo. Nessa perspectiva, o conhecimento é adquirido por meio de uma rede de conceitos interligados, em que conceitos simples se combinam para formar conceitos mais complexos, organizados em múltiplas camadas de processamento. Essa profundidade de representação torna possível que o sistema aprenda características abstratas dos dados sem depender de instruções explícitas, consolidando o *Deep Learning* como a principal base técnica dos modelos de linguagem contemporâneos (GOODFELLOW; BENGIO; COURVILLE, 2016).

Nesse sentido de evolução das abordagens de IA, os *Large Language Models* (LLMs) representam um avanço significativo, caracterizando-se pelo grande número de parâmetros e pela capacidade de realizar tarefas complexas de linguagem natural. Esses modelos são treinados em larga escala, com bilhões de parâmetros e grandes volumes de dados textuais, o que lhes confere habilidades emergentes que não estão presentes em modelos menores. Entre essas habilidades estão o *in-context learning*, que permite resolver novas tarefas a partir de poucos exemplos, e a geração de respostas contextualizadas e coerentes em diferentes domínios. Os LLMs têm impulsionado uma transformação profunda nas áreas de Inteligência Artificial e Processamento de Linguagem Natural, possibilitando o desenvolvimento de sistemas como o ChatGPT, capazes de interagir com seres humanos de maneira flexível e adaptável (ZHAO et al., 2023).

Dessa forma, observa-se que o conceito de IA evoluiu de abordagens voltadas à imitação do comportamento humano para modelos capazes de aprender e agir racionalmente

em ambientes complexos. O avanço das técnicas de aprendizado profundo consolidou uma nova etapa desse processo, permitindo que sistemas construam representações hierárquicas do conhecimento e aprendam de forma autônoma a partir de grandes volumes de dados. Nesse contexto, os *Large Language Models* (LLMs) representam o ápice recente dessa evolução, integrando princípios de IA e *Deep Learning* para compreender, interpretar e gerar linguagem natural com elevado grau de precisão e adaptabilidade. A compreensão desses fundamentos é essencial para o desenvolvimento de soluções que explorem o potencial dessas tecnologias, o que será aprofundado nas próximas seções, ao se abordar as técnicas de Recuperação Aumentada por Geração (*Retrieval-Augmented Generation* – RAG) e suas aplicações no contexto jurídico.

2.2 Recuperação Aumentada por Geração (RAG)

A crescente complexidade dos modelos de linguagem e a necessidade de ampliar sua capacidade de fornecer respostas precisas e verificáveis impulsionaram o desenvolvimento de novas abordagens de integração entre recuperação de informação e geração de texto. Entre essas abordagens, destaca-se a *Recuperação Aumentada por Geração* (*RAG*), proposta por Lewis et al. (2020), que combina um módulo de busca de conhecimento com um modelo generativo. Essa técnica permite que o sistema consulte bases de dados externas antes de formular uma resposta, utilizando as informações recuperadas como contexto para a geração textual. De acordo com Gao et al. (2023), o RAG constitui um avanço essencial para tarefas intensivas em conhecimento, pois reduz alucinações, melhora a rastreabilidade e torna as saídas dos modelos de linguagem mais transparentes e confiáveis. Dessa forma, o RAG estabelece uma ponte entre o aprendizado profundo e a recuperação de informação, permitindo que sistemas baseados em IA, como o *IAJuris*, produzam respostas fundamentadas em fontes verificáveis e em consonância com os princípios de precisão e responsabilidade informacional.

Com a consolidação desse paradigma, novas variações arquiteturais passaram a ser desenvolvidas para aprimorar cada etapa do processo. A literatura recente classifica a arquitetura do RAG em três paradigmas principais: *Naive RAG*, *Advanced RAG* e *Modular RAG*. O primeiro adota uma estrutura linear de etapas (*retrieve–read–generate*); o segundo aprimora a etapa de recuperação por meio de técnicas de pré e pós-processamento, como reescrita de consultas e reranqueamento; e o terceiro introduz módulos substituíveis e adaptativos que permitem reorganizar o fluxo de interação entre as partes do sistema (GAO et al., 2023). Essa modularidade aumenta a flexibilidade e facilita a integração do RAG com outras técnicas, como *fine-tuning*, *reinforcement learning* e controle de qualidade do contexto recuperado. Entre essas evoluções, destacam-se modelos que ampliam a autonomia do próprio sistema na etapa de busca.

Entre essas evoluções, destacam-se modelos que ampliam a autonomia do próprio sistema na etapa de busca. Com base em Shuster et al. (SHUSTER et al., 2022), uma das evoluções mais relevantes é o modelo *SeeKeR* (*Search, Knowledge, Response*), que amplia a estrutura tradicional do RAG ao permitir que o modelo de linguagem execute buscas ativas em fontes externas antes de gerar sua resposta. Essa abordagem introduz um ciclo dinâmico de *busca–filtragem–geração*, em que o modelo avalia continuamente a necessidade de novas consultas para melhorar a completude e a precisão das respostas. Segundo os autores, essa modularização favorece a atualização contínua do conhecimento e a capacidade de lidar com informações em rápida mudança, característica essencial em domínios como o jurídico, que exige precisão temporal e respaldo documental.

Para aprimorar a etapa de recuperação, Khattab et al. (2021) propuseram o *ColBERT-QA*, um método baseado em interação tardia entre tokens que equilibra eficiência computacional e alta precisão semântica. Ao comparar representações vetoriais de cada token da consulta e dos documentos, o modelo calcula uma matriz de similaridade que preserva nuances lexicais e contextuais. Essa técnica se mostrou mais eficaz que métodos densos tradicionais em tarefas de *open-domain QA*, pois recupera passagens mais relevantes mesmo diante de ambiguidades linguísticas. No contexto do RAG, o uso de retrievers desse tipo é fundamental para garantir que as informações utilizadas na geração provenham de trechos juridicamente significativos e semanticamente próximos às consultas originais.

Embora o RAG tenha alcançado avanços notáveis, Gao et al. (2023) destacam que persistem desafios técnicos e éticos. Entre eles estão a dificuldade de avaliar sistematicamente a qualidade da recuperação e da geração, a dependência de fontes externas potencialmente enviesadas e o aumento da latência computacional devido ao processo de busca em tempo real. Contudo, os mesmos autores ressaltam que o RAG mantém papel insubstituível, mesmo frente a modelos com janelas de contexto muito amplas, pois oferece maior interpretabilidade e rastreabilidade do raciocínio (GAO et al., 2023). No caso do *IAJuris*, a aplicação desse paradigma possibilita combinar grandes modelos de linguagem com bases oficiais de jurisprudência, assegurando que cada resposta gerada possa ser verificada por meio das fontes originais e auditada quanto à sua confiabilidade.

Em síntese, a Recuperação Aumentada por Geração consolida-se como uma das abordagens mais promissoras para ampliar a confiabilidade dos modelos de linguagem em tarefas intensivas em conhecimento. Ao combinar a precisão dos mecanismos de busca semântica com a flexibilidade da geração de texto, o RAG permite que sistemas baseados em IA incorporem informações atualizadas e verificáveis em suas respostas (LEWIS et al., 2020; GAO et al., 2023). As evoluções mais recentes, como as arquiteturas modulares propostas por Shuster et al. (SHUSTER et al., 2022) e as técnicas de recuperação contextualizada apresentadas por Khattab et al. (KHATTAB et al., 2021), reforçam o papel

do RAG como componente essencial para o desenvolvimento de aplicações baseadas em grandes modelos de linguagem. No contexto do *IAJuris*, essa integração é particularmente relevante, pois viabiliza a construção de respostas fundamentadas em fontes oficiais e rastreáveis, alinhando inovação tecnológica, responsabilidade informacional e rigor jurídico. Essa perspectiva conduz à necessidade de discutir princípios éticos e diretrizes de governança que orientem o uso responsável dessas tecnologias, tema abordado na próxima seção.

2.3 Ética, Governança e Diretrizes

A adoção de sistemas de Inteligência Artificial (IA) em domínios sensíveis requer mecanismos que garantam responsabilidade, rastreabilidade e alinhamento com valores sociais e regulatórios. Nos últimos anos, organismos internacionais como a ISO, o NIST e instituições de pesquisa propuseram modelos e normas que transformam princípios éticos em requisitos técnicos e processos auditáveis. Essa integração entre ética, governança e mensuração de desempenho estabelece as bases para o desenvolvimento responsável de aplicações baseadas em IA generativa, como o *IAJuris*.

Os conceitos apresentados nesta seção têm caráter estritamente teórico e servem como base para compreender os requisitos de confiabilidade, transparência e controle aplicáveis a sistemas de IA. O detalhamento operacional de avaliação, documentação e gestão de risco será desenvolvido no capítulo de Metodologia.

Estudos comparativos sobre diretrizes de ética em IA indicam uma convergência internacional em torno de valores centrais como transparência, justiça, não maleficência, responsabilidade e privacidade. Corrêa (2022) analisaram mais de duzentas diretrizes globais e constataram que, embora exista consenso em torno desses princípios, há carência de instrumentos normativos que operacionalizem sua aplicação em contextos organizacionais. Essa lacuna justifica o avanço de frameworks e normas técnicas voltadas a transformar recomendações éticas em práticas verificáveis e compatíveis com sistemas de gestão.

O modelo *hourglass*, proposto por Mäntymäki et al. (2022), traduz princípios éticos em mecanismos de governança distribuídos em três camadas complementares: o ambiente externo (*environmental layer*), que envolve regulações, padrões e valores sociais; a camada organizacional (*organizational layer*), que define papéis, responsabilidades e políticas internas; e a camada do sistema de IA (*AI system layer*), dedicada à implementação técnica, avaliação e melhoria contínua. Essa estrutura permite alinhar decisões estratégicas a práticas operacionais, conectando ética e conformidade técnica. A governança proposta destaca que a responsabilidade pela IA é compartilhada entre diferentes níveis da organização e deve ser sustentada por processos de monitoramento, auditoria e documentação contínua.

A norma ISO/IEC 42001:2023 estabelece os requisitos para um Sistema de Gestão

de Inteligência Artificial (*AI Management System*), integrando práticas de governança, gestão de riscos e melhoria contínua. De acordo com a norma, as organizações devem definir políticas documentadas, atribuir responsabilidades à alta direção, planejar ações para lidar com riscos e oportunidades e manter registros das decisões tomadas. O padrão enfatiza que o ciclo de vida da IA deve ser controlado de modo sistemático, abrangendo desde a concepção até a desativação do sistema. Além disso, recomenda-se a integração do SGIA com outros sistemas de gestão, como segurança da informação (ISO/IEC 27001), privacidade (ISO/IEC 27701) e qualidade (ISO 9001), garantindo coerência e interoperabilidade entre controles de diferentes domínios (ISO/IEC..., 2023).

O *AI Risk Management Framework*, publicado pelo National Institute of Standards and Technology (NIST) em 2023, propõe uma abordagem centrada na gestão de riscos associados a sistemas de IA. O framework define quatro funções fundamentais, *Govern*, *Map*, *Measure* e *Manage*, que abrangem desde a definição de políticas de governança até a mitigação de riscos identificados. Segundo o documento, a função *Govern* garante que valores éticos, responsabilidade e direitos humanos sejam incorporados ao processo decisório; a função *Map* descreve contextos e propósitos de uso da IA; a função *Measure* estabelece métricas e métodos de avaliação de desempenho e impacto; e a função *Manage* consolida ações de mitigação e melhoria contínua (ARTIFICIAL..., 2023). O NIST enfatiza que o gerenciamento de risco deve ser contínuo, proporcional ao nível de impacto potencial e orientado à transparência e confiança.

A norma ISO/IEC TS 4213:2022 complementa as práticas de governança ao definir métodos padronizados para a avaliação de classificadores baseados em aprendizado de máquina. O documento descreve um processo composto por cinco etapas — planejamento, definição de métricas, execução, análise e reporte — e orienta sobre a escolha de indicadores adequados a diferentes tipos de tarefas (binárias, multiclasse e multilabel). Entre as métricas recomendadas estão acurácia, precisão, *recall*, F1, área sob a curva ROC (AUC-ROC) e área sob a curva de precisão-revocação (AUC-PRC). A norma alerta que a acurácia isolada pode ser inadequada em bases desbalanceadas e recomenda o uso de métricas complementares e análise estatística para comparações significativas, como testes t pareados ou Wilcoxon (ISO/IEC..., 2022). A adoção desses padrões assegura que o desempenho de sistemas de IA seja mensurado de maneira justa, transparente e reprodutível.

A convergência entre princípios éticos, modelos organizacionais de governança e normas técnicas consolida um arcabouço de referência para o uso responsável da IA. Normas como a ISO/IEC 42001 e a ISO/IEC TS 4213 oferecem requisitos concretos e métricas de avaliação que se articulam com frameworks de gestão de risco como o NIST AI RMF e com modelos de governança como o *hourglass*. Essa integração fornece uma base sólida para o desenvolvimento do *IAJuris*, assegurando que o sistema adote práticas

auditáveis, rastreáveis e compatíveis com padrões internacionais de ética, desempenho e governança.

2.4 Direito, Jurisprudência e Segurança Jurídica

O Direito é um sistema normativo que tem por objetivo garantir estabilidade, previsibilidade e justiça nas relações sociais. Sua efetividade depende da coerência entre normas, decisões e princípios que asseguram a confiança dos cidadãos nas instituições. Nesse contexto, a jurisprudência e o princípio da segurança jurídica ocupam papel central, pois estruturam a aplicação uniforme do Direito e previnem arbitrariedades no exercício da jurisdição.

Segundo Câmara (2011), o processo judicial é um instrumento de pacificação social que se consolida pela estabilidade das decisões e pela autoridade da coisa julgada. A previsibilidade e a coerência das decisões judiciais são condições indispensáveis para a efetividade da tutela jurisdicional. Nesse sentido, os precedentes judiciais possuem força normativa, garantindo que casos semelhantes recebam tratamento semelhante, o que preserva a isonomia e a racionalidade do sistema jurídico. Esse entendimento consolida a ideia de que a segurança jurídica se manifesta na estabilidade das decisões e na confiança legítima dos cidadãos quanto à previsibilidade do Direito (MARINONI, 2011).

Alexy (2011) amplia essa discussão ao destacar que o Direito é composto por regras e princípios, sendo estes mandamentos de otimização aplicáveis mediante ponderação racional. A aplicação do Direito, portanto, deve buscar a harmonização de valores em conflito, preservando a coerência e a integridade do sistema normativo. A hermenêutica constitucional impede o decisionismo e assegura a integridade das decisões judiciais. Logo, a coerência jurisprudencial é condição necessária à concretização da segurança jurídica, pois garante que o Direito se mantenha íntegro e previsível no tempo (STRECK, 2018).

A jurisprudência, entendida como o conjunto de decisões reiteradas dos tribunais sobre determinada matéria, exerce função orientadora e integradora do sistema jurídico. Marinoni (2011) explica que a observância dos precedentes não apenas assegura a uniformidade decisória, mas também representa um mecanismo de racionalidade que fortalece o Estado de Direito. A jurisprudência permite que o cidadão compreenda e antecipe as consequências jurídicas de seus atos, o que consolida a confiança pública nas instituições. Essa previsibilidade reforça o valor da igualdade perante a lei e reduz a insegurança provocada por interpretações contraditórias.

A discussão sobre coerência e integridade também dialoga diretamente com debates contemporâneos sobre tecnologia e ética. Conforme Floridi (2023) contribui com a base filosófica dessa governança ao propor cinco princípios éticos para a IA, beneficência, não maleficência, autonomia, justiça e explicabilidade, que orientam a relação entre tecnologia,

Direito e sociedade. O autor enfatiza que a explicabilidade é um requisito essencial para a legitimidade de decisões automatizadas, pois garante que elas possam ser compreendidas e auditadas. Essa transparência é fundamental no contexto jurídico, em que a confiança pública depende da compreensão das razões que fundamentam as decisões. Além disso, Floridi destaca que a conformidade legal é necessária, mas não suficiente: é preciso que a governança da IA esteja orientada pelo que é moral e socialmente bom, de modo a harmonizar ética, regulação e prática institucional.

Em síntese, a segurança jurídica emerge como um valor estruturante que une tradição e inovação. Os fundamentos teóricos apresentados apontam caminhos para que a tecnologia se torne uma aliada desse princípio. O *IAJuris*, ao adotar práticas de transparência e explicabilidade, exemplifica a possibilidade de harmonizar a inovação tecnológica com os valores éticos e jurídicos que garantem a integridade e a confiança no sistema de justiça.

2.5 Critérios de Qualidade e Avaliação do Sistema

Este tópico apresenta os fundamentos teóricos que orientam a avaliação de sistemas como o *IAJuris*, considerando três camadas complementares: *Recuperação* (qualidade dos trechos jurídicos recuperados), *Geração* (fidelidade e utilidade do texto produzido a partir de fontes oficiais) e *Operacional* (qualidade do produto/serviço em uso).

Na camada de *Recuperação*, investiga-se a capacidade de um sistema de localizar e ranquear passagens juridicamente pertinentes às consultas. A literatura clássica de Recuperação da Informação estabelece que esse tipo de avaliação depende de uma coleção de documentos, necessidades informacionais definidas e julgamentos de relevância feitos por especialistas, configuração conhecida como *test collection* (MANNING; RAGHAVAN; SCHÜTZE, 2008). Nesse contexto, métricas como *Recall*@k, *Mean Reciprocal Rank* (MRR) e nDCG@k são amplamente utilizadas para mensurar a pertinência das respostas recuperadas, especialmente quando se busca avaliar a qualidade de rankings de documentos.

Na camada de *Geração*, a qualidade do texto produzido por modelos de linguagem é analisada com foco na *fidelidade* às fontes recuperadas (groundedness) e na *rastreabilidade* de citações, aspectos essenciais no domínio jurídico. A literatura recente estabelece dimensões de avaliação como groundedness, relevance, coherence e fluency, que normalmente estruturam rubricas de avaliação humana (METRICS..., 2024). Essas dimensões permitem verificar se as respostas geradas aderem ao contexto jurídico, apresentam consistência lógica e mantêm clareza textual adequada ao uso profissional.

A camada *Operacional* envolve atributos de qualidade de software e de serviço em produção. Normas como a ISO/IEC 25010 (ISO/IEC..., 2011) definem características de

produtos de software — desempenho, confiabilidade, usabilidade e segurança — enquanto a ISO/IEC 25012 (ISO/IEC..., 2008) trata da qualidade de dados, incluindo atualidade, integridade, consistência e completude, aspectos relevantes quando se opera com bases jurisprudenciais oficiais. Esses referenciais orientam a análise de fatores como latência, throughput e taxa de erro, associados ao desempenho real do sistema em operação.

Além disso, práticas de governança, documentação e gestão de risco são descritas em normas e frameworks internacionais. A ISO/IEC TS 4213 (ISO/IEC..., 2022) propõe diretrizes para a avaliação de sistemas de aprendizado de máquina, destacando a importância de métricas adequadas, prevenção de *leakage* e análise estatística apropriada. O *AI Risk Management Framework* do NIST (ARTIFICIAL..., 2023) complementa esses princípios ao estruturar a gestão de risco em funções como *Govern*, *Map*, *Measure* e *Manage*, que orientam desde a definição de objetivos até a mitigação de impactos e a transparência dos resultados.

De modo geral, a literatura indica três classes de indicadores amplamente utilizadas:

- **Recuperação**: métricas como Recall@k, MRR e nDCG@k, aplicadas sobre coleções com julgamentos de relevância (MANNING; RAGHAVAN; SCHÜTZE, 2008);
- **Geração**: avaliação humana baseada em groundedness, relevance, coherence e fluency (METRICS..., 2024);
- **Operacional**: indicadores de desempenho (latência p95/p99), throughput, taxa de falhas e medidas de qualidade de dados e software (ISO/IEC..., 2011; ISO/IEC..., 2008).

Assim, a avaliação do *IAJuris* apoia-se em fundamentos consolidados de Recuperação da Informação, análise de conteúdo gerado por modelos de linguagem e modelos de qualidade de software. Os procedimentos específicos adotados, tais como protocolos experimentais, técnicas de amostragem, instrumentos de avaliação humana e métodos estatísticos, serão discutidos em detalhes no capítulo de Metodologia.

2.6 Considerações Finais do Capítulo

Este capítulo apresentou a base conceitual necessária para o desenvolvimento do *IAJuris*. Inicialmente, foram delineados os fundamentos de Inteligência Artificial e de Modelos de Linguagem, destacando definições e capacidades essenciais para compreender o comportamento de sistemas que operam sobre linguagem natural. Em seguida, discutiu-se a Recuperação Aumentada por Geração (RAG) como abordagem que integra busca

e produção de texto, estabelecendo o papel dessa técnica na construção de respostas contextualizadas e verificáveis a partir de fontes oficiais.

Na sequência, foram sistematizados elementos de ética, governança e diretrizes aplicáveis ao ciclo de vida de sistemas de IA, com ênfase na necessidade de processos auditáveis, papéis claramente definidos e práticas de monitoramento contínuo. Esses aspectos foram articulados ao cenário jurídico, evidenciando como jurisprudência, coerência decisória e segurança jurídica funcionam como referenciais para o desenho e a operação de soluções tecnológicas em domínios sensíveis.

Por fim, consolidaram-se critérios de qualidade e estratégias de avaliação em três camadas complementares, recuperação, geração e operação, antevendo métricas, instrumentos e procedimentos que serão detalhados adiante. Com isso, este capítulo cumpre o objetivo de organizar o referencial teórico que sustenta as escolhas técnicas e metodológicas do projeto, preparando o terreno para a descrição dos materiais, dos métodos e do processo de desenvolvimento apresentados no próximo capítulo.

3 Referencial Tecnológico

Este capítulo apresenta o conjunto de ferramentas, plataformas e tecnologias que serviram de apoio para a condução desta pesquisa. A seleção de cada item foi pautada em critérios como maturidade da tecnologia, comunidade de desenvolvedores, gratuidade (ou ampla disponibilidade) e adequação aos objetivos do projeto.

O referencial foi dividido em três categorias, conforme a definição do projeto: ferramentas de escrita, ferramentas de desenvolvimento do protótipo e ferramentas auxiliares à pesquisa.

3.1 Ferramentas de Escrita e Documentação

3.1.1 Overleaf e LaTeX

Para a redação deste Trabalho de Conclusão de Curso, foi utilizado a plataforma **Overleaf**, um editor de LaTeX colaborativo baseado na web.

A escolha pelo LaTeX como sistema de formatação de texto se deve à sua superioridade na composição de documentos acadêmicos e científicos. Ele permite um controle preciso sobre a diagramação, a gestão automatizada de referências bibliográficas (via BibTex), a numeração de seções, figuras e tabelas, e a renderização de blocos de código-fonte, garantindo um resultado final com alto padrão de qualidade editorial.

Figura 1 – Plataforma Overleaf utilizada no desenvolvimento dessa monografia

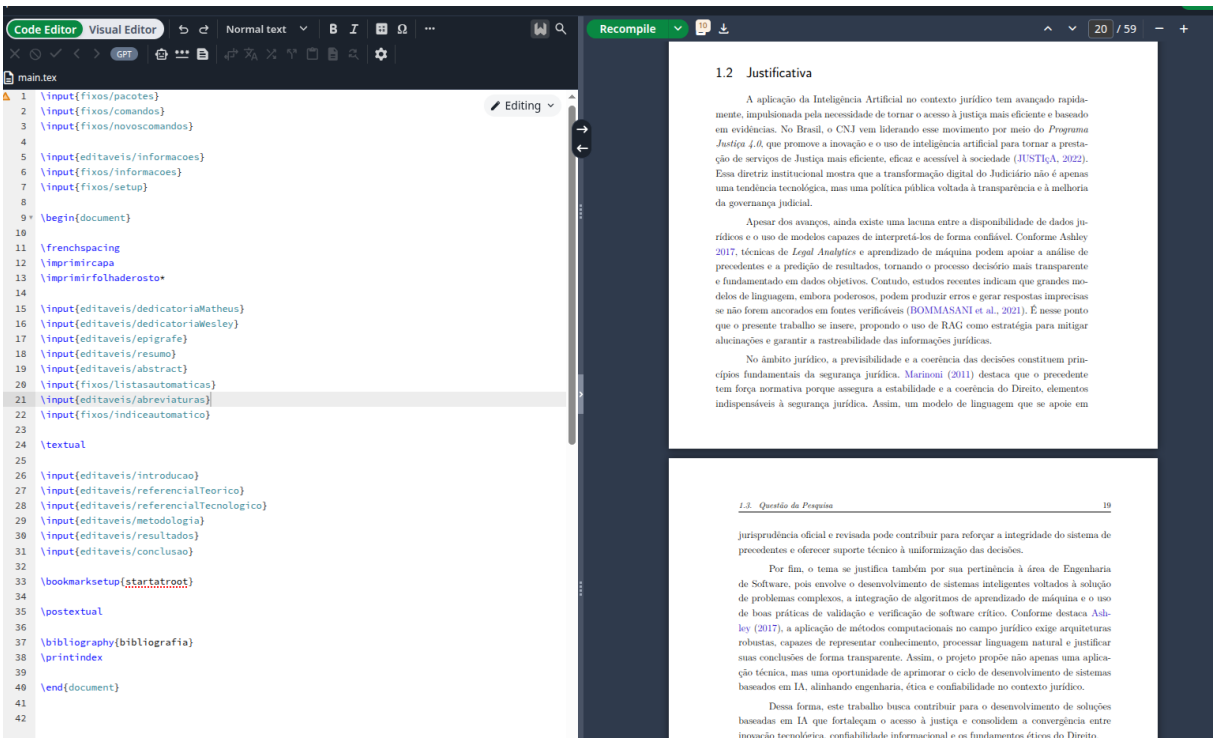

3.2 Tecnologias de Desenvolvimento do Protótipo

O protótipo de software, denominado *IA-Juris*, foi planejado para ser desenvolvido utilizando um conjunto de tecnologias mordernas e de código aberto, centradas no ecossistema Python.

3.2.1 Python

A linguagem de programação **Python** (versão 3.10 ou superior) foi a escolha principal para todo o *backend* do projeto. Sua sintaxe clara e principalmente o seu robusto ecossitema de bibliotecas nativas (como `json` e `sqlite3`) e de Inteligência Artificial (Google Generativa AI) a tornarem a opção ideal para a rápida prototipação e desenvolvimento do sistema.

3.2.2 FastAPI e Uvicorn

Para a construção da API REST, o *framework* **FastAPI** foi escolhido. O motivo é por ser um *framework* web moderno e de alta performance, que utiliza os recursos assíncronos da linguagem Python. Sua escolha se justifica por:

- **Validação de Dados**: Utilização nativa do Pydantic para validar os tipos de dados de entrada e saída, garantindo a robustez da API.

- **Documentação Automática**: Geração de documentação interativa (Swagger UI e ReDoc) de forma automática, o que foi crucial para os testes.

- **Perfomance**: Alta velocidade de resposta, sendo um dos *frameworks* Python mais rápidos disponíveis.

O **Uvicorn** foi utilizado como o servidor ASGI (Asynchronous Server Gateway Interface) para poder executar a aplicação FastAPI.

3.2.3 SQLite e a Biblioteca JSON

Para a persistência e recuperação dos dados textuais (ementas), a biblioteca nativa **SQLite** (através do módulo `sqlite3`) foi escolhida como o banco de dados do sistema.

A escolha se deu por conta da sua natureza *serveless* (um único arquivo `juris.db`), que retira a necessidade de um servidor de banco de dados complexo. A principal justificativa técnica para o SQLite foi sua poderosa extensão **FTS5 (Full-Text Search)**. O FTS5 nos traz a funcionalidade de *retrieval* (recuperação) necessária para o RAG, permitindo buscas textuais complexas e ranqueadas por relevância em milhões de documentos de forma instantânea.

Para a leitura dos dados de origem obtidos, foi utilizado a biblioteca nativa **JSON** do Python, capaz de processar (fazer o *parse*) dos arquivos de *datasets* baixados do STJ.

3.3 Ferramentas Auxliares à Pesquisa

Além das ferramentas de escrita e desenvolvimento, um conjunto de serviços e softwares de apoio foi utilizado para viabilizar a pesquisa.

3.3.1 Portal de Dados Abertos (STJ)

A fonte de dados principal do projeto foi o **Portal de Dados Abertos do Superior Tribunal de Justiça (STJ)**. Diferente de APIs de consulta em tempo real (como o DataJud, que é focado em estatísticas e nos metadados) ou do *web scraping* (bloqueado por reCAPTCHA), o Portal de Dados Abertos se mostrou a fonte ideal para o projeto.

Figura 2 – Portal de Dados Abertos do STJ usado como fonte de dados

Ele disponibiliza *datasets* completos dos "Espelhos de Acórdãos"em formato **JSON** para *download* direto. Esta abordagem garantiu o acesso ao texto integral das ementas de forma oficial, estruturados e robusta, sendo a fonte de todo o conhecimento carregado no banco de dados no *IAJuris*.

3.3.2 Postman

Para o teste e validação do *endpoint* `/consultar-jurisprudencia`, foi utilizada a ferramenta **Postman**. Este cliente de API permite a simulação de requisições POST em formato JSON, possibilitando a depuração e a verificação das respostas da API do *IA-Juris* em tempo real.

Figura 3 – Ferramenta para a chamada de requisições da API IA-Juris

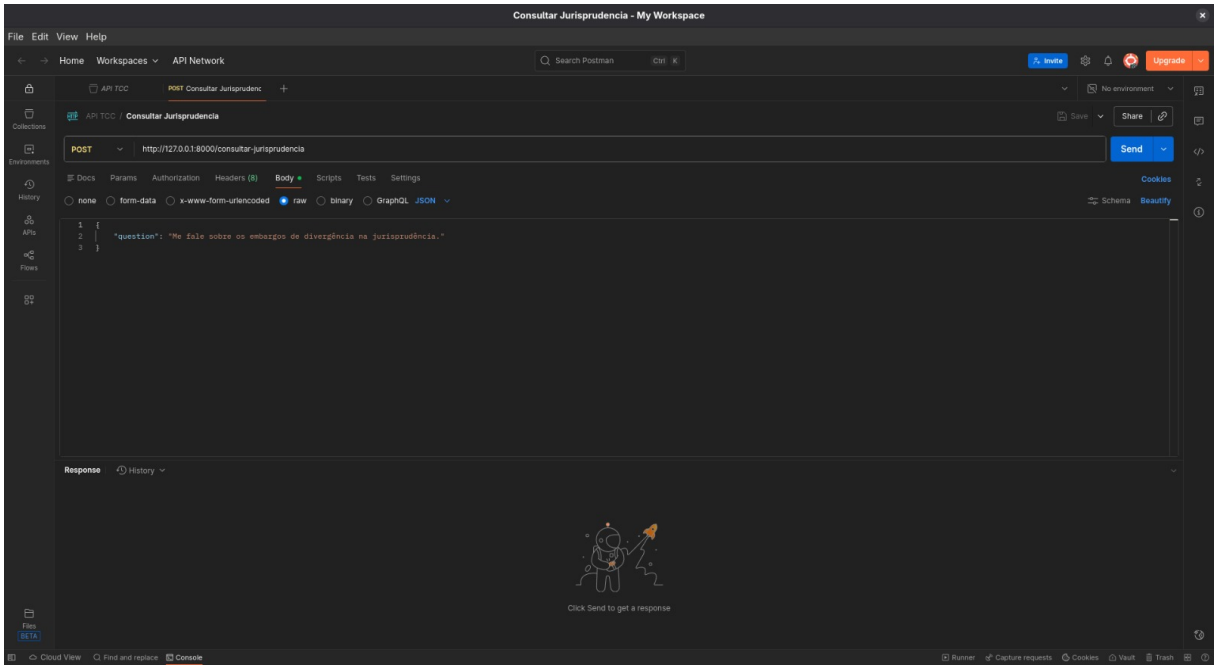

3.3.3 Visual Studio Code (VS Code)

Todo o desenvolvimento do código-fonte foi realizado no Ambiente de Desenvolvimento Integrado (IDE) **Visual Studio Code**. Por conta de sua popularidade, vasto ecossistema de extensões para Python (como o Pylance) e a integração com o terminal facilitarram o fluxo de trabalho.

Figura 4 – Ferramenta IDE para a codificação da API IA-Juris

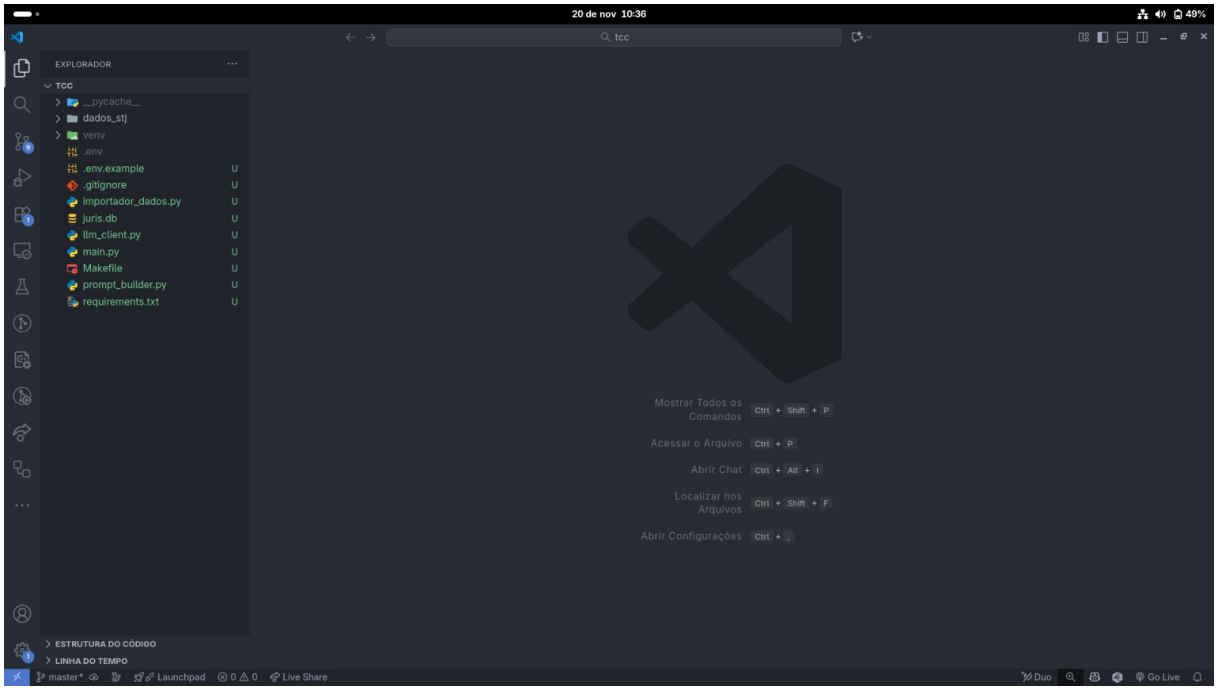

3.3.4 Makefile

Para automatizar tarefas repetitivas de gerenciamento de projeto, foi criado um **Makefile**. Este arquivo deine comandos simplificados, como `make install` (para instalar dependências), `make collect` (para executar o coletor de dados) e `make-run` (para iniciar o servidor), tornando o ambiente de desenvolvimento mais eficiente e padronizado.

4 Metodologia

Este capítulo descreve o método adotado para conceber, documentar, implementar e avaliar o *IAJuris*, articulando: (i) o desenho do produto (descoberta, objetivos e escopo), (ii) a preparação de dados e governança, (iii) a arquitetura técnica baseada em *Retrieval-Augmented Generation* (RAG), e (iv) o plano de avaliação técnica e operacional com validação estatística. A estrutura enfatiza reprodutibilidade, documentação de dados e mensuração responsável de desempenho, alinhando boas práticas e normas.

4.1 Desenho do produto e planejamento

A fase de desenho do produto foi conduzida por um workshop de *Lean Inception*, cuja finalidade é **alinhar pessoas e convergir para um MVP** por meio de uma sequência curta e estruturada de atividades colaborativas. O objetivo central é que o time **descubra e compreenda coletivamente o que será desenvolvido** e **planeje a entrega incremental** do produto com foco em valor ao usuário e viabilidade ao final de uma semana de trabalho intensivo (CAROLI, 2019).

Escolheu-se a *Lean Inception* por organizar a ideação em um conjunto claro de atividades (visão, objetivos, personas, jornadas, funcionalidades, sequenciador e *Canvas* do MVP) que reduzem a incerteza inicial e favorecem decisões de curto prazo orientadas a valor. O resultado esperado do workshop é um **MVP bem definido** e um **plano de ondas (slices) para incrementos subsequentes**, com rastro explícito entre hipóteses, necessidades de usuários e funcionalidades priorizadas (CAROLI, 2019).

O workshop ocorre tipicamente ao longo de uma **semana**, com agenda pública de atividades e marcos de alinhamento (abertura, checkpoints e *showcase* final). A participação alterna momentos de colaboração ampliada (com *stakeholders*) e sessões de trabalho com o núcleo do time. As atividades progridem de *porquês* (visão e objetivos) para *para quem* (personas e jornadas) e então para *o quê e quando* (funcionalidades, priorização e sequenciador), culminando no **Canvas do MVP** (CAROLI, 2019).

Tabela 1 – Artefatos produzidos no workshop de *Lean Inception* do projeto IAJuris.

Artefato	**Descrição e propósito (visão geral da metodologia)**
Visão do Produto	Define, de forma sintética, o propósito central do produto, seu público-alvo e a proposta de valor. Orienta todas as decisões posteriores da inception.
Produto É / Não É / Faz / Não Faz	Delimita o escopo conceitual, estabelecendo fronteiras claras sobre o que o produto contempla e o que está fora do escopo, evitando expectativas desalinhadas.
Personas	Representam perfis fictícios, mas realistas, dos usuários-alvo. Ajudam a equipe a entender necessidades, dores, motivações e comportamentos relevantes para o produto.
Jornadas do Usuário	Descrevem o fluxo de ações que cada persona realiza para atingir um objetivo. Permitem identificar pontos de dor e oportunidades onde o produto pode gerar valor.
Brainstorming de Funcionalidades	Atividade divergente para levantar, sem restrições iniciais, todas as possíveis funcionalidades do produto. Amplia o espaço de soluções antes da priorização.
Agrupamento das Funcionalidades	Organização das funcionalidades levantadas em temas ou categorias, facilitando análise, discussão e preparação para atividades de priorização.
Revisão Técnica, de Negócio e de UX	Avalia cada funcionalidade por três perspectivas: viabilidade técnica, valor de negócio e impacto na experiência do usuário, equilibrando diferentes dimensões do produto.
Matriz de Prioridade (Esforço–Negócio–UX)	Instrumento para comparar e ordenar funcionalidades de forma estruturada, permitindo evidenciar itens de alto valor e fácil implementação.
Sequenciador de Funcionalidades	Distribui funcionalidades em ondas evolutivas, estabelecendo ordem lógica e incremental de entrega. Indica quando e em que sequência cada item deve ser construído.
Definição do MVP	Recorte mínimo que reúne valor, usabilidade e viabilidade. Determina o menor conjunto de funcionalidades capaz de validar hipóteses essenciais do produto.
Canvas do MVP	Quadro síntese que consolida hipóteses, público-alvo, funcionalidades mínimas, métricas e riscos. Serve como guia para desenvolvimento e validação do MVP.
Registro Consolidado	Documento de formalização contendo os participantes, datas, dinâmica utilizada e todos os artefatos produzidos, garantindo rastreabilidade do processo.
Lições Aprendidas	Reflexões sobre o processo, destacando o que funcionou bem, limitações percebidas e aprendizados relevantes para fases posteriores do projeto.
Próximos Passos	Lista das ações planejadas após a inception, geralmente incluindo desenvolvimento, testes, configuração de ambiente e validações iniciais.

O encerramento do workshop entrega: (i) **MVP definido**, (ii) **sequenciador por ondas** (plano de incrementos) e (iii) **artefatos de alinhamento** (visão, objetivos, personas e jornadas). Esses insumos guiam o capítulo de Desenvolvimento (implementação por

slices) e fundamentam o capítulo de Avaliação (métricas e critérios previamente pensados junto às necessidades mapeadas) (CAROLI, 2019).

4.2 Dados, documentação e governança

A preparação dos dados (coleta, composição, pré-processamento, usos e manutenção) é o pilar de qualquer sistema de *Retrieval-Augmented Generation* (RAG). A metodologia deste projeto seguiu um processo alinhado a prospecção, seleção e processamento da fonte de dados, com o objetivo de garantir a **transparência**, **reprodutibilidade** e **adequação ao propósito** (*fit-for-purpose*) dos dados, assim alinhando-se aos princípios recomendados e presentes em *Datasheets for Datasets* (GEBRU et al., 2021).

Em relação a *confiabilidade* e *explicabilidade*, foi adotado o panorama de *trustworthiness* do *ISO/IEC TR 24028*, com ênfase na **explicabilidade por proveniência**: o sistema deve ser capaz de rastrear cada informação gerada de volta à sua fonte original (ISO/IEC, 2020).

4.2.1 Prospecção e Seleção da Fonte de Dados

A fase de prospecção nos ajudou a avaliar múltiplas estratégias para a obtenção dos textos de jurisprudência (ementas e acórdãos), resultando em uma decisão metodológica que buscou como prioridade a robustez e a oficialidade dos dados.

Tabela 2 – Fontes-alvo e análise de viabildiade para o RAG.

Fonte	**Análise de Viabilidade (Prós e Contras)**	**Decisão Metodológica**
Web Scraping (HTML)	*Prós:* Acesso ao conteúdo mais recente. *Contras:* Extrema fragilidade (quebra com mudanças de layout); bloqueado por mecanismos de defesa (ex: **reCAPTCHA v3**) identificados no portal do STJ;	**Rejeitada.** Risco de falha técnica e bloqueio.
API DataJud (CNJ)	*Prós:* API oficial, estruturada (JSON), unificada. *Contras:* Análise demonstrou ser uma API de **metadados estatísticos** (andamentos, classes), não fornecendo os textos integrais das ementas.	**Rejeitada.** Inadequada para o objetivo de RAG.
Dados Abertos (STJ e STF)	*Prós:* Fonte oficial do tribunal; dados fornecidos em **formato PDF** de *download*; contém os **textos completos** das ementas. *Contras:* Dados não são em tempo real (atualizados em *snapshots* mensais).	**Aprovada.** Acesso direto ao texto, alta confiabilidade e alinhamento com as boas práticas de consumo de dados públicos.

A metodologia escolhida foi por conta do uso exclusivo dos *datasets* de "Espelhos de Acórdãos"do **Portal de Dados Abertos do STJ**. Essa escolha excluí os problemas de

web scraping (HTML/PDF/OCR) e da API Datajud. A troca da atualização em tempo real por *snapshots* mensais foi considerada uma troca aceitável em relação a estabilidade, confiabilidade e o volume dos dados.

4.2.2 Conversão, Estruturação e Carga (ETL)

Diferente a uma pipeline de *scraping* que iria exigir a conversão de PDF e OCR, o processo escolhido é um *Extract, Transform, Load* (ETL) sobre os dados já estruturados.

(i) **Extração (Extract):** Localizar os múltiplos arquivos '.json' baixados do Portal de Dados Abertos, ler os arquivos inteiros em memória e realizar o processo de *parse* do *array*.

(ii) **Transformação (Transform):** Para cada registro, extrair os campos-chaves definidos no modelo de dados (ver Seção 4.2.3), sendo o campo *"ementa"* o principal. A única transformação aplicada consiste na validação da existência do texto da ementa (Portão chave).

(iii) **Carga (Load):** Os registros extraídos são carregados em um banco de dados **SQlite** local (*juris.db*). Este banco de dados vai servir como a base de conhecimento do nosso sistema RAG.

Em síntese, o processo de ETL adotado estabelece um fluxo simples, direto e adequado ao contexto do projeto, priorizando eficiência e rastreabilidade dos dados utilizados na construção da base de conhecimento do sistema RAG. Ao operar exclusivamente sobre arquivos já estruturados, evita-se a complexidade de técnicas de OCR ou extração textual avançada, permitindo que o foco permaneça na curadoria dos campos relevantes e na consistência das informações carregadas. Esse pipeline garante que os dados jurídicos sejam armazenados de forma organizada e acessível, constituindo um repositório confiável para as etapas seguintes de indexação, recuperação e geração aumentada por evidências.

4.2.3 Modelo de dados comum

O esquema comum adotado tem como foco na necessidade do RAG. A tabela *ementas* do SQlite será definida com os seguintes campos, extraídos do JSON de origem:

- `processo_num`: Chave textual para identificação.
- `descricao_classe`: Metadado contextual.
- `orgao_julgador`: Metadado contextual.
- `ministro_relator`: Metadado contextual.

- `data_publicacao`: Metadado contextual.
- `texto_ementa`: O documento textual a ser indexado e recuperado.

A definição desse modelo de dados comum estabelece a estrutura mínima necessária para que o mecanismo de recuperação opere com consistência e precisão. Ao separar claramente os metadados contextuais do conteúdo principal,no caso a ementa, o banco de dados torna-se mais eficiente tanto para indexação quanto para filtragem e análise posterior. Essa organização também facilita a rastreabilidade das decisões recuperadas, permitindo que o sistema RAG associe corretamente cada passagem ao processo e ao contexto em que foi proferida. Dessa forma, o esquema proposto fornece uma base sólida e padronizada para todas as etapas subsequentes do pipeline jurídico.

4.2.4 Documentação e Transparência (Princípios do Datasheet)

Durante em nosso processo e metodologia, apesar de não termos criado um *Datasheet for Datasets* (GEBRU et al., 2021) do zero, o mesmo adotou os seus princípios. Por selecionar o Portal de Dados Abertos, no fim herdamos a documentação e a governança do próprio STJ:

- **Motivação e Composição:** O portal do STJ já nos fornece o "Dicionário de Dados"que descreve o propósito de cada campo.
- **Processo de Coleta:** A nossa coleta é transparente (download de arquivos públicos, e o próprio STJ version os *snapshots* por data, o que garante a reprodutilidade.
- **Usos Recomendados:** A finalidade do portal é explicitamente o reuso dos dados, alinhando-se perfeitamente ao nosso objetivo.

Os princípios do *Data Statements for NLP* (BENDER; FRIEDMAN, 2018) são parcialmente contemplados por estarmos lidando com um domínio linguístico específico (Português Jurídico, do STJ) e o RAG aplicado garante que o LLM seja exposto a essa variedade textual.

4.2.5 Privacidade e Confiança

Ao utilizar os dados públicos e oficiais, partimos com a premissa de que o tratamento de privacidade (anonimização de partes sensíveis) já foi realizada na origem pelo próprio tribunal, assim conforme a legislação de dados públicos.

A nossa arquitetura reforça a *trustworthiness* (ISO/IEC, 2020) através da **explicabilidade por proveniência**:

- **Rastreabildiade:** O texto gerado pelo LLM é fundamentado e contextualizado em ementas reais.

- **Verificação:** A API retorna os processos utilizados como fonte, permitindo que o usuário final ou um auditor valide a fonte exata da informação, dessa forma mitigando "alucinações"do LLM.

Com isso, a arquitetura proposta busca consolidar um ambiente de uso confiável, no qual cada resposta gerada possa ser auditada e compreendida em sua origem. Ao garantir que o modelo opere exclusivamente sobre dados públicos já tratados pelos próprios tribunais e ao reforçar mecanismos de rastreabilidade e verificação, o sistema estabelece condições práticas para mitigar riscos de privacidade, reduzir incertezas sobre a veracidade das informações e promover maior transparência no uso de IA generativa no contexto jurídico. Dessa forma, a camada de privacidade e confiança deixa de ser apenas um requisito normativo e passa a compor um elemento estruturante da robustez do IAJuris.

4.2.6 Indexação para RAG (FTS5 vs. Vetores)

A seção 4.3 (Arquitetura) irá detalhar o RAG, mas a metodologia de **indexação** dos dados será definida aqui. O rascunho original, pensado, desde trabalho considerava uma indexação em dois níveis (lexical e vetorial).

Após uma análise, a metodologia foi refinada e repensada para usar **exclusivamente um índice lexical de alta perfomance: SQlite FTS5 (Full-Text Search)**.

O motivo que levou a decisão de **não usar índices vetoriais** (embeddings) foi uma escolha metodológica consciente:

1. **Adequação ao Domínio:** A busca jurídica depende fortemente de termos exatos (ex: "Embargos de divergência", "Agravo Interno"). O uso de busca por similaridade semântica (vetores) pode "errar", e assim trazer "embargos de declaração"quando o usuário foi específico.

2. **Complexidade vs. Retorno:** A implementação de uma pipeline vetorial (armazenamento vetorial) traria ao projeto uma complexidade massiva.

3. **Performance do FTS5:** O FTS5 incluí algoritmos de ranqueamento que demonstraram o suficiente para o propósito do projeto, combinando a precisão da busca literal com a simplicidade de implementação (um único arquivo `juris.db`).

Por fim, a base de conhecimento do *IAJuris* consiste em uma tabela virtual FTS5, que provê a funcionalidade de *retrieval* (recuperação) para o RAG.

4.3 Arquitetura técnica (visão geral)

A arquitetura do *IAJuris* adota o padrão *RAG*: consultar uma base de conhecimento local (jurisprudência oficial) antes de responder e usar o conteúdo recuperado como contexto para a geração. A formulação de RAG e seus benefícios de rastreabilidade e transparência em tarefas intensivas em conhecimento seguem (LEWIS et al., 2020) e o panorama de (GAO et al., 2023).

4.3.1 Justificativa da Arquitetura: RAG-Lite com FTS5

A metodologia original (descrita na Seção 4.2) considerou diversas arquiteturas de *retrieval*, incluindo sistemas complexos baseados em vetores como (KHATTAB et al., 2021).

Entretanto, uma decisão metodológica principal foi adotar uma arquitetura **RAG-Lite**, que utiliza um índice lexical (Busca Full-Text) em vez de um indíce vetorial. A escolha pelo **SQLite FTS5 (Full-Text Search)** foi escolhida pelos seguintes motivos:

1. **Adequação ao Domínio Jurídico:** A busca por jurisprudência depende fortemente da precisão de termos técnicos (ex: "embargos de divergência"), onde a busca lexical exata é superior â similaridade semântica (vetores).

2. **Simplicidade e Performance:** O FTS5 é *serveless* (contido em um único arquivo `juris.db`, nativo do Python, e oferece perfomance de busca instantânea sem a complexidade de gerenciar modelos de *embedding* ou banco vetoriais.

3. **Viabilidade de Protótipo:** Está abordagem permitiu focar no fluxo de orquestração do RAG, que é o núcleo deste trabalho, em vez de focar na infraestrutura do **retriever**.

Em síntese, a adoção do modelo RAG-Lite com FTS5 representa uma escolha metodológica consciente, alinhada tanto às necessidades específicas do domínio jurídico quanto às limitações práticas de desenvolvimento de um protótipo acadêmico. Ao privilegiar precisão lexical, simplicidade operacional e desempenho imediato, a arquitetura proposta reduz a complexidade inicial sem comprometer a funcionalidade essencial do sistema. Essa decisão permite concentrar esforços na validação do fluxo de recuperação e geração, que constitui o foco central do trabalho, ao mesmo tempo em que estabelece uma base robusta e extensível para futuras evoluções que possam incorporar técnicas vetoriais mais avançadas.

4.3.2 Fluxo de Execução da API

O sistema é orquestrado por uma API **FastAPI** que executa o fluxo RAG em tempo real a cada pergunta vinda do usuário. O processo segue as seguintes seis etapas:

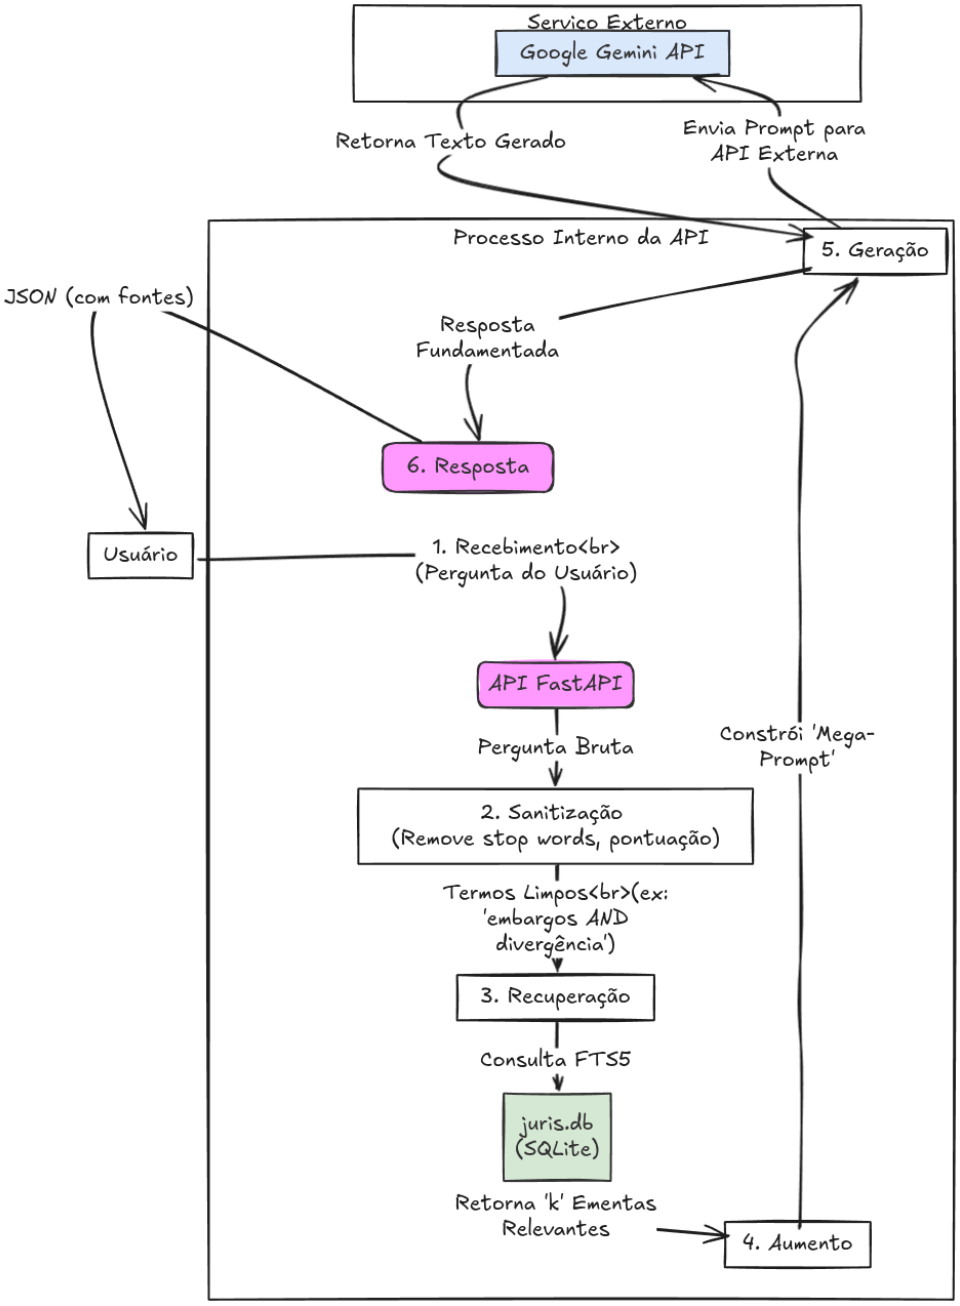

Figura 5 – Fluxo de execução da API

1. **Recebimento:** A API recebe a pergunta do usuário (ex: "Fale sobre embargos de divergência").

2. **Sanitização:** A pergunta é "sanitizada": convertida em letras minúsculas, tem a pontuação removida e as *stop words* (palavras comuns como "o", "de", "fale") são filtradas.

3. **Recuperação:** Script executa uma consulta FTS5 (ex: `MATCH 'embargos AND divergência'`) no banco de dados `juris.db`.

4. **Aumento:** O banco retorna as k ementas mais relevantes (ordenadas por `rank`). Há o script responsável por construir o 'mega-prompt"e injetar os textos dessas ementas reais como contexto.

5. **Geração:** O script responsável por envio irá pegar o "mega-prompt"e enviar para a API do Google Gemini, com instruções para basear a resposta exclusivamente nas fontes fornecidas.

6. **Resposta:** Por fim, a API retorna ao usuário a resposta gerada pelo LLM, juntamente com os números dos processos que foram usados, garantindo assim a rastreabilidade da fonte utilizada.

Com esse fluxo, a API consolida uma execução RAG totalmente integrada, na qual cada etapa contribui para garantir precisão, rastreabilidade e aderência ao conteúdo jurídico fornecido. A estrutura em etapas bem definidas não apenas facilita a compreensão interna do funcionamento do sistema, mas também assegura transparência e auditabilidade, elementos essenciais para o uso de IA no domínio jurídico. Ao retornar tanto a resposta quanto as fontes utilizadas, o processo reforça a confiabilidade do IAJuris e estabelece uma base sólida para futuras extensões, ajustes ou substituição modular de componentes, caso arquiteturas mais avançadas de recuperação ou geração sejam incorporadas posteriormente.

4.4 Avaliação experimental, métricas e testes do sistema

A avaliação do *IAJuris* combina **método experimental** e **testes sistemáticos** em diferentes níveis. Do ponto de vista de engenharia de software, o planejamento, a execução, a análise e o reporte dos experimentos seguem um ciclo explícito de definição de objetivos, fatores, variáveis de resposta, instrumentos de coleta e ameaças à validade, conforme orientações para experimentação em engenharia de software empírica (WOHLIN et al., 2012). Do ponto de vista das métricas, adotamos um conjunto de medidas alinhadas às tarefas centrais do sistema — recuperação de passagens jurídicas, geração de respostas fundamentadas e operação contínua — em consonância com práticas consolidadas na literatura de Recuperação da Informação e avaliação de sistemas de IA (MANNING; RAGHAVAN; SCHÜTZE, 2008; ISO/IEC..., 2022; ARTIFICIAL..., 2023).

Do lado da **reprodutibilidade**, cada experimento será documentado com: versão do conjunto de dados (instantâneo e manifestos descritos na Seção 4.2), versão do índice lexical (SQLite FTS5), configuração do modelo (versão do LLM, forma de acesso via API,

prompts e parâmetros de inferência), hiperparâmetros do módulo de recuperação (tipo de índice, tamanho de *top-k*, filtros) e descrição do ambiente computacional (bibliotecas, hardware). Essa documentação segue a boa prática de coleções de teste com consultas e julgamentos de relevância na literatura de RI (MANNING; RAGHAVAN; SCHÜTZE, 2008), articulada às recomendações de escolha e reporte de métricas para módulos de aprendizado de máquina (ISO/IEC. . . , 2022).

No nível de **testes de software**, o projeto contemplará:

- *Testes unitários* de componentes centrais (parsers de decisões, normalização de texto, segmentação em passagens, adaptadores de API e funções de cálculo de métricas);
- *Testes de integração* entre o pipeline de dados, os índices de recuperação e o módulo de geração, garantindo que mudanças em um componente não quebrem a cadeia de ponta a ponta;
- *Testes de sistema* e *testes de regressão* sobre cenários completos de uso (consultas-tipo e casos de referência), de modo a verificar que a qualidade da recuperação, da geração e da operação não se degrada ao longo de iterações;
- *Testes específicos para LLM+RAG*, incluindo:
  - **Regressão de *prompts***: conjunto fixo de consultas e instruções-chave, com respostas de referência, para detectar mudanças inesperadas de comportamento após ajustes de configuração ou atualização do modelo;
  - **Testes de *grounding***: verificação sistemática de que trechos citados nas respostas aparecem nas passagens recuperadas, bem como de que não há referências a fontes inexistentes;
  - **Testes de robustez a consultas adversariais**: consultas ambíguas, mal formuladas, excessivamente longas ou com ruído, avaliando se o sistema mantém respostas prudentes e devidamente fundamentadas;
  - **Testes de falha controlada**: situações em que a recuperação retorna poucas ou nenhuma passagem relevante, ou a API do modelo falha, verificando se o sistema responde de forma segura (mensagens de impossibilidade, ausência de "palpites" não fundamentados) e registra o erro adequadamente.

Esses testes complementam a avaliação experimental: enquanto os experimentos quantificam desempenho em conjuntos de teste, os testes automatizados asseguram que o comportamento esperado seja mantido durante a evolução do sistema.

4.4.1 Métricas principais

Considerando os objetivos do *IAJuris*, priorizamos métricas em três grupos: **Recuperação**, **Geração** e **Operação**. Abaixo estão as medidas centrais que serão monitoradas e reportadas.

A avaliação da recuperação será feita sobre coleções de teste com consultas representativas e julgamentos de relevância por especialistas, estrutura clássica para avaliação de RI (MANNING; RAGHAVAN; SCHÜTZE, 2008). As métricas prioritárias incluem:

- **Recall@k**: proporção de decisões ou passagens relevantes recuperadas entre as k primeiras posições;
- **MRR (Mean Reciprocal Rank)**: média do inverso da posição da primeira passagem relevante, enfatizando quão cedo o sistema apresenta conteúdo útil;
- **nDCG@k (Normalized Discounted Cumulative Gain)**: qualidade do ranqueamento até a posição k, ponderando a relevância e a ordem dos resultados.

Ao analisar essas métricas, levaremos em conta evidências sobre a *estabilidade* de medidas de avaliação, isto é, o quanto pequenas alterações em tópicos ou julgamentos podem afetar as conclusões, de modo a dimensionar adequadamente o número de consultas e a interpretação dos resultados (BUCKLEY; VOORHEES, 2000).

Para o módulo de geração, o foco recai sobre a **fidelidade às fontes oficiais** e a **utilidade jurídica** das respostas. A avaliação será predominantemente humana, com uso de uma rubrica estruturada em dimensões:

- **Groundedness/fidelidade**: o quanto a resposta está estritamente apoiada nas passagens recuperadas, sem introduzir conteúdo não suportado;
- **Relevância**: adequação da resposta à consulta e ao problema jurídico proposto;
- **Coerência**: consistência interna, ausência de contradições e organização lógica do texto;
- **Fluência**: clareza, correção linguística e legibilidade em português jurídico.

Os avaliadores registrarão justificativas e apontarão exatamente quais trechos das decisões sustentam cada parte da resposta, preservando rastreabilidade. A definição dessas dimensões dialoga com propostas recentes de avaliação holística de modelos de linguagem, que enfatizam a necessidade de combinar métricas quantitativas com julgamentos humanos bem documentados (BOMMASANI et al., 2022).

Na camada operacional, acompanharemos indicadores de qualidade de produto e de dados em linha com os modelos de qualidade de software e de dados (ISO/IEC..., 2011; ISO/IEC..., 2008):

- **Latência p95/p99**: tempo de resposta percebido pelo usuário em percentis altos (95 e 99), relevante para uso interativo;
- **Throughput**: número de requisições atendidas por unidade de tempo em condições típicas de carga;
- **Taxa de erro**: proporção de chamadas com falhas técnicas (timeouts, exceções) ou respostas inválidas;
- **Atualidade da base**: tempo médio entre a publicação de decisões oficiais e sua incorporação ao índice;
- **Completude e consistência**: proporção de documentos com metadados essenciais preenchidos e ausência de conflitos ou duplicidades na base de jurisprudência.

Esses indicadores alimentam um painel de operação contínua, permitindo monitorar aderência a requisitos de desempenho, confiabilidade e qualidade de dados.

4.4.2 Validação estatística e comparação de variantes

Quando o estudo envolver **comparações entre variantes** (por exemplo, comparado o RAG-FTS5 com uma busca simples (LIKE) ou com o LLM sem RAG, seguiremos diretrizes para análise estatística em cenários com múltiplas tarefas e coleções, evitando uso inadequado de testes paramétricos simples e acurácia isolada (DEMŠAR, 2006; ISO/IEC..., 2022). Em particular:

- a análise de métricas de recuperação ao longo de múltiplas consultas seguirá procedimentos não paramétricos adequados para comparações pareadas;
- em avaliações de geração com notas humanas, serão aplicados testes pareados sobre as pontuações por item, com justificativa explícita da escolha do teste e dos pressupostos considerados;
- em cenários com múltiplos sistemas e múltiplas métricas, será aplicada correção para múltiplas comparações, conforme orientações específicas para experimentos em NLP (DROR et al., 2018).

Por fim, o processo de avaliação será enquadrado em um **ciclo de gestão de risco** compatível com o NIST AI RMF, em que resultados de métricas e análises estatísticas

alimentam as funções de *Map*, *Measure* e *Manage* para identificação de riscos, mensuração de impacto e definição de ações de mitigação, sob uma governança explícita da IA no contexto do *IAJuris* (ARTIFICIAL..., 2023).

4.5 Considerações Finais do Capítulo

Este capítulo apresentou a metodologia adotada para o desenvolvimento do *IAJuris*, articulando de forma integrada os processos de concepção do produto, preparação dos dados, definição da arquitetura técnica e planejamento da avaliação do sistema. Inicialmente, o uso do *Lean Inception* permitiu estruturar a visão do projeto, esclarecer objetivos e consolidar artefatos que orientaram a construção do protótipo. Em seguida, foi detalhado o processo de prospecção, seleção e organização das bases oficiais de jurisprudência, destacando práticas de documentação, governança e confiabilidade de dados essenciais para sistemas que operam em domínios sensíveis.

A arquitetura adotada foi justificada com base nas características do domínio jurídico e nas necessidades práticas do protótipo, evidenciando a escolha por uma abordagem RAG simplificada apoiada em busca lexical via FTS5. Essa decisão privilegiou rastreabilidade, desempenho e viabilidade de implementação, mantendo alinhamento com princípios de explicabilidade e fundamentação das respostas. Por fim, foram apresentados os critérios teóricos de avaliação do sistema, contemplando camadas de Recuperação, Geração e Operação, bem como métricas amplamente aceitas na literatura e referências normativas aplicáveis à avaliação de sistemas de IA.

Em conjunto, esses elementos estabelecem um percurso metodológico claro, reprodutível e consistente com os objetivos do projeto. O próximo capítulo descreve a implementação prática do *IAJuris*, evidenciando como as decisões metodológicas aqui definidas foram aplicadas na construção do sistema.

5 Resultados

5.1 Resultados do Lean Inception

A realização da Lean Inception permitiu consolidar um conjunto abrangente de artefatos que definiram de forma clara o escopo inicial, o entendimento dos usuários e o formato do Produto Mínimo Viável (MVP) do sistema IAJuris. Todos os resultados foram coletados em reuniões conduzidas entre 20 e 24 de outubro de 2025, realizadas por meio de Google Meet, com registro integral no Google Docs. A seguir, apresenta-se uma síntese estruturada dos artefatos produzidos, conforme registrado no documento final do processo.

A visão do produto ficou consolidada como "IAJuris – Integração de IA Generativa com Bases Oficiais de Jurisprudência", cujo propósito é fornecer uma ferramenta capaz de realizar buscas jurídicas confiáveis, diretamente em fontes oficiais, complementadas por mecanismos de inteligência artificial para sumarização e contextualização das decisões encontradas. Durante as discussões, alinhou-se que o produto deve ser simples, preciso e transparente quanto às fontes utilizadas, sobretudo considerando o perfil dos clientes envolvidos.

Para delimitar o escopo, foi construído o artefato *Produto é / não é / faz / não faz*, que serviu para evitar interpretações equivocadas. Como resultado, estabeleceu-se que o produto é um sistema de consulta jurisprudencial integrado a tribunais oficiais; não é uma plataforma de gestão processual; faz a recuperação, exibição, organização e explicação de decisões; e não faz automação completa de documentos jurídicos nem substitui o trabalho do advogado. Esse quadro norteou todas as etapas seguintes, garantindo foco e viabilidade dentro do contexto acadêmico.

O desenvolvimento das personas resultou na criação de dois perfis centrais, que sintetizam as necessidades reais dos usuários. A primeira persona, Dra. Carolina Mendes, representa advogadas autônomas que enfrentam dificuldades ao lidar com a grande variedade de termos jurídicos, a insegurança sobre a confiabilidade das fontes e o esforço exigido para filtrar manualmente decisões semelhantes. Ela espera precisão, rastreabilidade e simplicidade na interface. A segunda persona, Dr. Ricardo Albuquerque, é sócio de um pequeno escritório, responsável por supervisionar advogados e revisar peças. Suas principais dores incluem ausência de padronização entre os sistemas dos tribunais, tempo excessivo para validar fontes e preocupação constante com atualizações jurisprudenciais. Ele espera organização por relevância, rastreamento direto ao documento oficial e redução significativa do tempo gasto por sua equipe na busca por precedentes.

Com base nessas personas, foram mapeadas duas jornadas de uso. Na jornada de Carolina, o fluxo inicia-se com a definição do problema jurídico, seguida por buscas amplas, filtragens repetitivas, leitura extensa e validação manual das decisões. Já na jornada de Ricardo, as atividades envolvem acompanhar a produção de sua equipe, revisar decisões selecionadas e garantir que cada peça esteja fundamentada em jurisprudência atualizada e confiável. As jornadas evidenciaram pontos de dor que justificam diretamente funcionalidades como filtros precisos, apresentação padronizada de decisões e links diretos para fontes oficiais.

A etapa de brainstorming de funcionalidades resultou em uma lista diversificada de capacidades desejadas. Para organizar essas ideias, as funcionalidades foram agrupadas em categorias, estruturadas no documento como apresentado na Tabela 3. Cada funcionalidade também recebeu avaliação de valor de negócio, impacto na experiência do usuário e viabilidade técnica, permitindo montar a matriz de priorização.

Tabela 3 – Agrupamento das funcionalidades levantadas na Lean Inception

Categoria	**Funcionalidades Identificadas**
Busca	Sugestões automáticas de termos jurídicos; filtros por tribunal, data e tipo de decisão.
Resultados	Exibição de resumo da decisão; ordenação por relevância e data; link direto para fonte oficial.
Interface	Interface simples com campo de busca central; destaque para tribunal e data da decisão.
Inteligência Artificial	Identificação automática de contexto; geração de resumo explicativo; detecção de possíveis “alucinações”.

A matriz de priorização mostrou que funcionalidades como “link direto para fonte oficial”, “interface simples com campo de busca central” e “exibição de resumo da decisão” apresentaram alto valor e alta viabilidade. Por outro lado, a “detecção de alucinações da IA” foi classificada como de alto valor, porém baixa viabilidade no contexto imediato, sendo destinada a incrementos posteriores. Essa priorização permitiu transformar um conjunto extenso de ideias em um planejamento executável, preservando coerência com a limitação temporal do TCC.

Com base na priorização, foi construído o sequenciador de funcionalidades, que distribuiu as entregas em ondas progressivas. As primeiras ondas concentraram funcionalidades essenciais para a operação mínima do sistema como mecanismo de busca, filtros básicos, exibição padronizada de decisões e acesso direto às fontes oficiais. As ondas seguintes contemplaram funcionalidades de maior complexidade técnica, sobretudo as dependentes de modelos de IA mais sofisticados. O sequenciador forneceu o roteiro necessário para definir o MVP, assegurando que o primeiro incremento fosse pequeno, funcional e validável pelos clientes.

A definição do MVP estabeleceu a hipótese central do projeto: a integração entre IA generativa e bases oficiais de jurisprudência pode tornar o processo de pesquisa mais preciso, rápido e confiável. O público-alvo para validação foi limitado às personas já desenvolvidas, representando advogados autônomos e pequenos escritórios. As funcionalidades mínimas definidas como obrigatórias foram: mecanismos básicos de busca; aplicação de filtros essenciais; exibição padronizada das decisões; link direto a documentos oficiais; e geração de resumos explicativos utilizando IA. Funcionalidades mais complexas ficaram propostas como extensões futuras.

O Canvas do MVP consolidou essas decisões em uma estrutura única, reunindo o propósito, as funcionalidades essenciais, as métricas de avaliação e os riscos identificados. Entre as métricas, destacaram-se a clareza dos resultados, a satisfação dos usuários após testes com o protótipo e a comparação entre o tempo necessário para a pesquisa manual e a pesquisa facilitada pelo IAJuris. Entre os riscos registrados estão a falta de padronização entre tribunais, a necessidade de atualização contínua das bases e o cuidado com possíveis inconsistências geradas pela IA.

O encerramento da Lean Inception consistiu na apresentação e validação de todos os artefatos produzidos. Os clientes confirmaram que a visão, o MVP e o sequenciador representavam adequadamente suas expectativas e necessidades reais. Também foram definidos os próximos passos: desenvolvimento do protótipo funcional, configuração do ambiente técnico, realização de testes de usabilidade e posterior análise dos resultados. Assim, a Lean Inception forneceu um conjunto de artefatos completos, validados e alinhados, servindo como base estruturada para a etapa de desenvolvimento no TCC2.

Referências

ALEXY, R. *Teoria dos Direitos Fundamentais*. [S.l.]: Malheiros, 2011. Citado na página 29.

ARTIFICIAL Intelligence Risk Management Framework (AI RMF 1.0). [S.l.], 2023. Citado 4 vezes nas páginas 28, 31, 47 e 51.

ASHLEY, K. D. *Artificial Intelligence and Legal Analytics: New Tools for Law Practice in the Digital Age*. Cambridge: Cambridge University Press, 2017. Citado na página 20.

BENDER, E. M.; FRIEDMAN, B. Data statements for natural language processing: Toward mitigating system bias and enabling better science. *Transactions of the ACL*, v. 6, p. 587–604, 2018. Citado na página 43.

BOMMASANI, R. et al. *On the Opportunities and Risks of Foundation Models*. Stanford, 2021. Citado 2 vezes nas páginas 19 e 20.

BOMMASANI, R. et al. *Holistic Evaluation of Language Models (HELM)*. [S.l.], 2022. Citado na página 49.

BUCKLEY, C.; VOORHEES, E. M. Evaluating evaluation measure stability. In: *Proceedings of the 23rd Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*. Athens, Greece: ACM, 2000. Citado na página 49.

CAROLI, P. *Lean Inception: Como alinhar pessoas e construir o produto certo*. São Paulo: Editora Caroli, 2019. Citado 2 vezes nas páginas 39 e 41.

CORRÊA, e. *Worldwide AI Ethics: a review of 200 guidelines and recommendations for AI governance*. 2022. Citado na página 27.

CâMARA, A. F. *Lições de Direito Processual Civil*. [S.l.]: Lumen Juris, 2011. Citado na página 29.

DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006. Citado na página 50.

DROR, R. et al. The hitchhiker's guide to testing statistical significance in natural language processing. In: *ACL*. [S.l.: s.n.], 2018. Citado na página 50.

FLORIDI, L. *The Ethics of Artificial Intelligence: Principles*. Oxford, United Kingdom: Oxford University Press, 2023. ISBN 9780198883098. Citado na página 29.

GAO, X. et al. Retrieval-augmented generation for knowledge-intensive nlp tasks: A survey. *arXiv preprint arXiv:2310.07923*, 2023. Citado 3 vezes nas páginas 25, 26 e 45.

GEBRU, T. et al. Datasheets for datasets. *Communications of the ACM*, v. 64, n. 12, p. 86–92, 2021. Citado 2 vezes nas páginas 41 e 43.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge: MIT Press, 2016. Disponível em <https://www.deeplearningbook.org/>. Citado na página 24.

ISO/IEC. *ISO/IEC TR 24028:2020 — Information technology — Artificial intelligence — Overview of trustworthiness in AI*. 2020. Citado 2 vezes nas páginas 41 e 43.

ISO/IEC 25010:2011 — Systems and software engineering — Systems and software Quality Requirements and Evaluation (SQuaRE) — System and software quality models. 2011. Citado 3 vezes nas páginas 30, 31 e 50.

ISO/IEC 25012:2008 — Software engineering — Software product Quality Requirements and Evaluation (SQuaRE) — Data quality model. 2008. Citado 2 vezes nas páginas 31 e 50.

ISO/IEC 42001:2023 — Artificial intelligence — Management system. 2023. International Organization for Standardization. Citado na página 28.

ISO/IEC TS 4213:2022 — Artificial intelligence — Assessment of machine learning classification performance. [S.l.], 2022. Citado 5 vezes nas páginas 28, 31, 47, 48 e 50.

JUSTIçA, B. C. N. de. *Programa Justiça 4.0: Balanço do 1º ano*. Brasília: CNJ/PNUD, 2022. Citado na página 20.

KHATTAB, O. et al. Relevance-guided supervision for openqa with colbert. *arXiv preprint arXiv:2109.06723*, 2021. Citado 2 vezes nas páginas 26 e 45.

LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. Citado 3 vezes nas páginas 25, 26 e 45.

MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to Information Retrieval*. Cambridge: Cambridge University Press, 2008. Citado 5 vezes nas páginas 30, 31, 47, 48 e 49.

MÄNTYMÄKI, M. et al. Putting ai ethics into practice: The hourglass model of organizational ai governance. 2022. Citado na página 27.

MARINONI, L. G. *Precedentes Obrigatórios*. São Paulo: Revista dos Tribunais, 2011. Citado 2 vezes nas páginas 20 e 29.

MCCARTHY, J. *What is Artificial Intelligence?* 2007. <http://www-formal.stanford.edu/jmc/whatisai.html>. Revised November 12, 2007. Citado na página 23.

METRICS for evaluating LLM-generated content (groundedness, relevance, coherence, fluency). 2024. Microsoft Learn. Available online. Citado 2 vezes nas páginas 30 e 31.

RUSSELL, S. J.; NORVIG, P. *Inteligência Artificial: Uma Abordagem Moderna*. 4. ed. São Paulo: Pearson, 2022. Citado na página 23.

SHUSTER, K. et al. Language models that seek for knowledge. *arXiv preprint arXiv:2203.17247*, 2022. Citado na página 26.

STRECK, L. L. *Jurisdição Constitucional e Hermenêutica: Uma Nova Crítica do Direito*. [S.l.]: Livraria do Advogado, 2018. Citado na página 29.

SUSSKIND, R. *Tomorrow's Lawyers: An Introduction to Your Future*. 2. ed. Oxford: Oxford University Press, 2017. Citado na página 19.

UNESCO. *Recomendação sobre a Ética da Inteligência Artificial*. Paris: Organização das Nações Unidas para a Educação, a Ciência e a Cultura, 2021. Citado na página 19.

WOHLIN, C. et al. *Experimentation in Software Engineering*. Berlin: Springer, 2012. Citado na página 47.

World Economic Forum. *The Future of Jobs Report 2025*. Genebra: World Economic Forum, 2025. Citado na página 19.

ZHAO, W. X. et al. A survey of large language models. *arXiv preprint arXiv:2303.18223*, 2023. Disponível em: <https://arxiv.org/abs/2303.18223>. Citado na página 24.